



Linear Models for Classification

Dama Putra Sarpanda | Ferza Reyaldi | Irvan Kurniawan
09021181924016 | 09021281924060 | 09021181924159

Discriminant Functions




Fungsi Diskriminan dengan Dua Kelas

- Mulailah dengan 2 masalah kelas $t \in \{0, 1\}$
- Diskriminan linier sederhana

$$y(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + w_0$$


terapkan fungsi ambang batas untuk mendapatkan klasifikasi

- Proyeksi \mathbf{x} dalam \mathbf{w} Adalah $\frac{\mathbf{w}^T \mathbf{x}}{\|\mathbf{w}\|}$



Fungsi Diskriminan dengan Beberapa Kelas

- Diskriminan linier antara dua kelas terpisah dengan hyperplane
- Bagaimana cara menggunakan ini untuk beberapa kelas?
 - Metode satu lawan satu: buat pengklasifikasi $K-1$, antara C_k dan yang lainnya
 - Metode satu lawan satu: buat pengklasifikasi $K(K-1)/2$, di antara semua pasangan



Fungsi Diskriminan dengan Beberapa Kelas

- Solusinya adalah membangun K fungsi linier

$$y_k(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + w_{k0}$$


tetapkan x ke kelas $\arg \max_k y_k(x)$

- Memberikan wilayah keputusan konveks yang terhubung

$$\hat{\mathbf{x}} = \lambda \mathbf{x}_A + (1 - \lambda) \mathbf{x}_B$$

$$y_k(\hat{\mathbf{x}}) = \lambda y_k(\mathbf{x}_A) + (1 - \lambda) y_k(\mathbf{x}_B)$$

$$\Rightarrow y_k(\hat{\mathbf{x}}) > y_j(\hat{\mathbf{x}}), \forall j \neq k$$




Kuadrat Terkecil untuk Klasifikasi

- Bagaimana kita mempelajari batas keputusan ($\mathbf{w}_k, \mathbf{w}_{k0}$)?
- Salah satu pendekatan adalah dengan menggunakan kuadrat terkecil, mirip dengan regresi
- Temukan \mathbf{W} untuk meminimalkan kesalahan kuadrat pada semua contoh dan semua komponen vektor label:

$$E(\mathbf{W}) = \frac{1}{2} \sum_{n=1}^N \sum_{k=1}^K (y_k \mathbf{x}_n - t_{nk})^2$$

- Beberapa aljabar, menggunakan invers semu seperti dalam regresi

Permasalahan Kuadrat Terkecil



- Mudah dipisahkan oleh hyperplanes, tetapi tidak ditemukan menggunakan kuadrat terkecil!
- Mengatasi masalah ini dengan model yang lebih baik
- Pertama, lihat kriteria yang berbeda untuk diskriminan linier

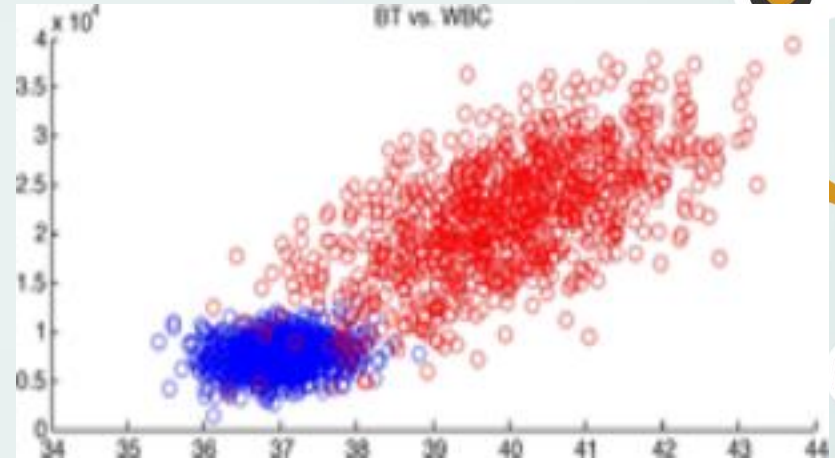
Diskriminan Linier Fisher

- Diskriminan linier dua kelas bertindak sebagai proyeksi:


$$y = \mathbf{w}^T \mathbf{x} \geq -w_0$$

diikuti oleh ambang batas

- Ke arah mana kita harus memproyeksikan?
- Yang memisahkan kelas "baik"



Diskriminan Linier Fisher



- Natural ide adalah memproyeksikan ke arah garis yang menghubungkan sarana kelas
- Namun, bermasalah jika kelas memiliki varian dalam arah ini
- Kriteria Fisher: memaksimalkan rasio pemisahan antar kelas (antar) terhadap variansi intra kelas (di dalam)

Ringkasan FLD


- FLD adalah teknik pengurangan dimensi
- Kriteria pemilihan proyeksi berdasarkan label kelas

Masih memiliki outlier (misalnya contoh kuadrat terkecil sebelumnya)

An abstract graphic on the left side of the slide. It features a central orange circle with a white border, surrounded by various organic, teardrop-like shapes in teal, dark grey, and white. Some shapes have smaller circles inside them, creating a layered, cellular effect. The background is a light blue-grey color.

Probabilistic Generative Models

Logistic Sigmoid



- Fungsi $\sigma(a) = \frac{1}{1 + \exp(-a)}$ diketahui sebagai logistic sigmoid
- Fungsi ini mengubah axis menjadi $[0, 1]$
- Berupa bilangan continuous dan bisa diturunkan
- Menghindari masalah yang diakibatkan oleh least-square error fitting yang terlalu tepat (nanti)




Multi-class Extension

- Ada generalisasi dimana logistic sigmoid $K > 2$ kelas:



$$\begin{aligned} p(C_k|\mathbf{x}) &= \frac{p(\mathbf{x}|C_k)p(C_k)}{\sum_j p(\mathbf{x}|C_j)p(C_j)} \\ &= \frac{\exp(a_k)}{\sum_j \exp(a_j)} \end{aligned}$$

dimana $a_k = \ln p(\mathbf{x}|C_k)p(C_k)$

Atau, **fungsi softmax**

- Jika beberapa $a_k \gg a_j$, $p(C_k|\mathbf{x})$ menuju 1
- 

Gaussian Class-Conditional Densities



- Kembali ke a di logistic sigmoid untuk 2 kelas
- Mari berasumsi densitas class-conditional $p(\mathbf{x}|C_k)$ adalah Gaussian, dan memiliki kovariansi yang sama dengan matrix Σ :

$$p(\mathbf{x}|C_k) = \frac{1}{(2\pi)^{D/2} |\Sigma|^{1/2}} \exp \left(-\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_k)^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}_k) \right)$$

- a mengambil bentuk sederhana:

$$a = \ln \frac{p(\mathbf{x}|C_1)p(C_1)}{p(\mathbf{x}|C_2)p(C_2)} = \mathbf{w}^T \mathbf{x} + w_0$$

- Catatan bahwa ketentuan kuadrat $\mathbf{x}^T \Sigma^{-1} \mathbf{x}$ batal

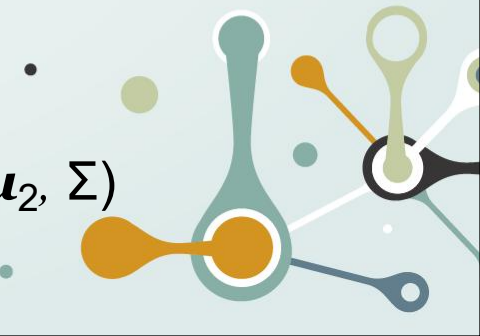


Maximum Likelihood Learning

- Kita bisa memasukkan parameter ke dalam model ini menggunakan **kemiripan maksimum**
 - Parameternya adalah $\boldsymbol{\mu}_1, \boldsymbol{\mu}_2, \Sigma^{-1}, p(C_1) \equiv \pi, p(C_2) \equiv 1 - \pi$
 - Dirujuk sebagai θ
- Untuk datapoint \mathbf{x}_n dari kelas C_1 ($t_n = 1$):

$$p(\mathbf{x}_n, C_1) = p(C_1)p(\mathbf{x}_n|C_1) = \pi N(\mathbf{x}_n|\boldsymbol{\mu}_1, \Sigma)$$

- Untuk datapoint \mathbf{x}_n dari kelas C_2 ($t_n = 0$):

$$p(\mathbf{x}_n, C_2) = p(C_2)p(\mathbf{x}_n|C_2) = (1 - \pi)N(\mathbf{x}_n|\boldsymbol{\mu}_2, \Sigma)$$




Maximum Likelihood Learning

- Kemiripan data latihan adalah:

$$p(\mathbf{t} | \pi, \mu_1, \mu_2, \Sigma) = \prod_{n=1}^N [\pi N(\mathbf{x}_n | \mu_1, \Sigma)]^{t_n} [(1 - \pi) N(\mathbf{x}_n | \mu_2, \Sigma)]^{1-t_n}$$

- Seperti biasa, ln adalah teman kita:

$$A(\mathbf{t}; \theta) = \sum_{n=1}^N t_n \ln \pi + (1 - t_n) \ln(1 - \pi) + t_n \ln N_1 + (1 - t_n) \ln N_2$$

- Maksimal untuk setiapnya secara terpisah

μ_1, μ_2, Σ





Maximum Likelihood Learning - Class Priors

- Memaksimalkan sehubungan dengan kelas prior parameter π sangat mudah:

$$\frac{\partial}{\partial \pi} A(\mathbf{t}; \theta) = \sum_{n=1}^N \frac{t_n}{\pi} - \frac{1}{1 - \pi}$$
$$\Rightarrow \pi = \frac{N_1}{N_1 + N}$$

- N_1 dan N_2 adalah angka untuk poin - poin latihan di setiap kelas
- Prior hanyalah sebagian dari poin - poin di setiap kelas



Maximum Likelihood Learning - Gaussian Parameters

- Parameter yang lain juga bisa ditemukan dalam bentuk yang sama
- Rata - rata kelas :

$$\boldsymbol{\mu}_1 = \frac{1}{N_1} \sum_{n=1}^N t_n \mathbf{x}_n$$



$$\boldsymbol{\mu}_2 = \frac{1}{N_2} \sum_{n=1}^N (1 - t_n) \mathbf{x}_n$$

- Rata - rata contoh latihan dari setiap kelas
- Matrix kovariansi terbagi:

$$\Sigma = \frac{N_1}{N} \frac{1}{N_1} \sum_{n \in C_1} (\mathbf{x}_n - \boldsymbol{\mu}_1)(\mathbf{x}_n - \boldsymbol{\mu}_1)^T + \frac{N_2}{N} \frac{1}{N_2} \sum_{n \in C_2} (\mathbf{x}_n - \boldsymbol{\mu}_2)(\mathbf{x}_n - \boldsymbol{\mu}_2)^T$$

- Bobot rata - rata dari kovariansi kelas

Gaussian dengan Kovariansi berbeda



$$a = \ln \frac{p(x|C_b)p(C_b)}{p(x|C_r)p(C_r)}$$

$$a = \underbrace{\ln(p(x|C_b)) - \ln(p(x|C_r))}_{-(x-\mu_b)^T \Sigma_b (x-\mu_b) + (x-\mu_r)^T \Sigma_r (x-\mu_r)} + \underbrace{\ln(p(C_b)) - \ln(p(C_r))}_{\text{Konstanta.}}$$



Rangkuman Probabilistic Generative Model

- Mencocokkan Gaussian menggunakan criterion machine learning sensitif terhadap outlier
- Bentuk linear sederhana untuk a di dalam logistic sigmoid terjadi lebih dari sekedar distribusi Gaussian
 - Muncul pada distribusi mana saja di dalam keluarga eksponensial, sebuah kelas besar dari distribusi



An abstract graphic on the left side of the slide. It features a central orange circle with a white border, surrounded by various organic, teardrop-like shapes in shades of teal, dark grey, and white. Some shapes have smaller circles inside them, creating a layered, cellular effect. The background is a light blue-grey color.

Probabilistic Discriminative Models



Support Vector Machine



- Pengembangan dari Perceptron yang dikembangkan oleh Rosenblatt pada tahun 1958.
- Perceptron menjamin bahwa Anda menemukan hyperplane jika ada.
- SVM menemukan margin maksimum yang memisahkan hyperplane.

Support Vector Machine

$$g(x) = w^T x + b$$


Maksimalkan k sedemikian rupa sehingga:

$$-w^T x + b \geq k \text{ untuk } d_i == 1$$


$$-w^T x + b \leq k \text{ untuk } d_i == -1$$

Nilai $g(x)$ tergantung pada $\|w\|$:

- Biarkan $\|w\| = 1$ dan maksimalkan nilai $g(x)$,
atau
- $g(x) \geq 1$ dan minimalkan nilai $\|w\|$



Support Vector Machine





Iterative Reweighted Least Squares




- Iterative reweighted least squares (IRLS) adalah metode penurunan seperti pada metode penurunan gradien.
- Kasus khusus dari metode **Newton-Raphson**
 - Fungsi Aproksimasi menggunakan ekspansi Taylor orde kedua:

$$\hat{f}(\boldsymbol{w}+\boldsymbol{v}) = f(\boldsymbol{w}) + \nabla f(\boldsymbol{w})^T(\boldsymbol{v}-\boldsymbol{w}) + \frac{1}{2}(\boldsymbol{v}-\boldsymbol{w})^T \nabla^2 f(\boldsymbol{w})(\boldsymbol{v}-\boldsymbol{w})$$

- Solusi bentuk tertutup untuk meminimalkan ini adalah *straight-forward*: kuadratik, turunan linier

Iterative Reweighted Least Squares

Grafik Metode **Newton-Raphson**






Resources



http://vda.univie.ac.at/Teaching/ML/15s/LectureNotes/04_classification.pdf

<https://www.ics.uci.edu/~xhx/courses/CS273P/05-linear-classification-273p.pdf>



Terima Kasih

